




Arquitectura Serverless 2026: Del Borde a la Multi-Nube

Manual Táctico de Rendimiento, Resiliencia
y FinOps para el Ecosistema Distribuido



LA GUERRA DE TITANES: RENDIMIENTO Y ESCALABILIDAD

DIAGNOSTIC MATRIX		
AWS Lambda	Azure Functions	Google Cloud Gen 2
Latencia Arranque en Frío: ~200-400ms	Latencia Arranque en Frío: ~400-700ms	Latencia Arranque en Frío: ~300-500ms
Límite Concurrencia: Escala rápido a 1,000 inst.	Límite Concurrencia: 5,000+	Límite Concurrencia: ~10,000
Punto Fuerte: Picos de tráfico explosivos	Punto Fuerte: Entornos empresariales sostenidos	Punto Fuerte: Cargas pesadas e IA



Análisis Base de Costos (Por Millón de Ejecuciones)

AWS Lambda


- ✓ Nivel Gratuito: 1M reqs / 400,000 GB-s
- \$ Costo de Ejecución: \$0.20
- 🔍 Costo Oculto: Tarifas de API Gateway y transferencia de datos

Azure Functions

- ✓ Nivel Gratuito: 1M reqs / 400,000 GB-s
- \$ Costo de Ejecución: \$0.22
- 🔍 Costo Oculto: Cargos por herramientas de monitoreo

Google Cloud Gen 2

- ✓ Nivel Gratuito: 2M reqs / 400,000 GB-s + 200,000 GHz-s
- \$ Costo de Ejecución: \$0.18
- 🔍 Costo Oculto: Modelo híbrido (factura GB-s y GHz-s)



PROVIDER	FREE TIER (INVOCATIONS PER MONTH)	FREE TIER (COMPUTE)*	INVOCATION COST (BEYOND FREE)	DURATION/MEMORY COST (BEYOND FREE)
AWS Lambda	1 million	400,000 GB-s	\$0.20 per 1M requests	\$0.00001667 per GB-s (100ms increments)
Azure Functions	1 million	400,000 GB-s	\$0.20 per 1M requests	~\$0.000016 per GB-s (100ms increments)
Google Cloud Functions (Gen 2)	2 million	400,000 GB-s + 200,000 GHz-s	\$0.40 per 1M requests	~\$0.000014 per GB-s + CPU charge**

La Frontera: El Borde vs. La Nube Central

Cloudflare Workers (El Borde)



- **Alcance:** 300+ PoPs globales
- **Arranque en Frío:** Sub-milisegundo (<1ms)
- **Límite de Memoria:** 128MB
- **Casos de uso:** Enrutamiento, Autenticación, Rate Limiting, IA en el borde

AWS Lambda (El Núcleo)




- **Alcance:** ~30 Regiones globales
- **Arranque en Frío:** Cientos de milisegundos
- **Límites:** Hasta 10GB RAM / 15 min. ejecución
- **Casos de uso:** Acceso VPC, ML Training pesado, procesamiento de video

La Paradoja de Costos de 2026: Rápido pero Letal

Agosto 2025: Cobro por fase INIT

El Avance Técnico:
Los tiempos de arranque en frío se redujeron un 80% (de 2s a 200ms) eliminando cuellos de botella en VPC.



El Impacto Matemático:
Antes: \$0.80 / millón inv. (Fase INVOKE)
Ahora: \$17.80 / millón inv. (INIT + INVOKE)
INCREMENTO DE COSTO: 22x

Los arranques en frío pasaron de ser un problema de latencia a un problema de presupuesto.